现代程序设计第4周作业

谢奕飞 20377077

代码

```
import pandas as pd
  from tqdm import tqdm
  import jieba
  import matplotlib.pyplot as plt
  def GetText(file_path):
      1.1.1
      数据读取函数
      传入txt文件绝对路径
10
      返回text列表
      f=open(file_path,'r',encoding='utf8')
      data=[]
14
      for line in tqdm(f.readlines()):
          text=''
          message=line.split()
          for each in message[2:-8]:
             text+=' '+each
          data.append(text)
20
      f.close()
      return data
  class Tokenizer:
24
      对自然语言进行编码
      111
      def __init__(self,texts,coding='c',PAD=0):
          输入将要需要操作的文本(一个字符串的列表)
          这里需要完成词典的构建(即汉字到正整数的唯一映射的确定)
          注意构建词典 一是要根据coding来选择按词构建(coding='w'),还是按字构建,默i
          self. texts=texts
          self._coding=coding
          self._PAD=PAD
          self._dic={}
          self._codes={PAD,}
          self._dic.update({'PAD':PAD})
```

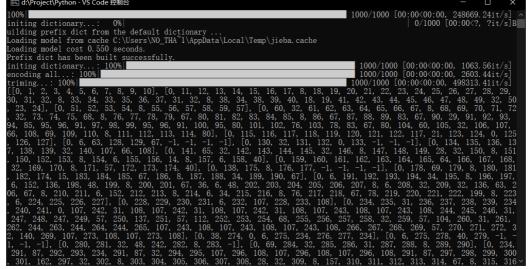
```
code=0
          for text in tqdm(texts,desc='initing dictionary...'):
              if coding=='w':
42
                  text=jieba.lcut(text)
              for word in text:
                  if word not in self._dic:
45
                      while code in self._codes:
                          code+=1
                      self._dic.update({word:code})
                      self._codes.add(code)
      def tokenize(self, sentence):
          输入一句话,返回分词(字)后的字符列表(list_of_chars)
          res=[]
          for each in tqdm(jieba.cut(sentence),desc='tokenizing...'):
              res.append(each)
          return res
       def encode(self,list_of_chars):
           1.1.1
          输入字符(字或者词)的字符列表,返回转换后的数字列表(tokens)
          tokens=[]
          for word in list_of_chars:
              tokens.append(self._dic[word])
          return tokens
       def trim(self,tokens,seq_len):
           111
          输入数字列表tokens,整理数字列表的长度。不足seq_len的 部分用PAD补足,超过的
70
          if len(tokens)>=seq_len:
              return tokens[:seq_len]
          else:
              return tokens.extend([self._PAD for i in range(len(tokens)-seq_1
       def decode(self, tokens):
           111
          将模型输出的数字列表翻译回句子。如果有PAD,输出'[PAD]'
           111
          res=''
          dic_list=[self._PAD for i in range(len(self._dic))]
          for each in self._dic:
              dic_list[self._dic[each]]=each
          for each in tokens:
              if each==self._PAD:
                  res+='[PAD]'
              else:
                  res+=dic_list[each]
          return res
```

```
def encode_all(self,seq_len):
        返回所有文本(chars)的长度为seq_len的tokens
        codes=[[] for i in range(len(self._texts))]
        i=0
        for text in tqdm(self._texts,desc='encoding all...'):
            if self._coding=='w':
                text=jieba.lcut(text)
            for word in text:
                codes[i].append(self._dic[word])
            i+=1
        for code in tqdm(codes,desc='triming...'):
            if len(code)<seq_len:</pre>
                code.extend([self._PAD for i in range(seq_len-len(code))])
            else:
                code=code[:seq_len]
        return codes
    def output_distribution(self):
        1.1.1
        输出编码分布
        111
        xy=\{\}
        for text in self._texts:
            if self._coding=='w':
                text=jieba.lcut(text)
            length=len(text)
            if length in xy:
                xy[length]+=1
            else:
                xy.update({length:1})
        x=sorted(xy.keys())
        y=[xy[key] for key in tqdm(x,desc='loading y...')]
        plt.bar(x,y)
        plt.xlabel('length')
        plt.ylabel('distribution')
        plt.show()
if __name__=='__main__': main()
```

测试encode_all()

```
| Company | Comp
```

修改传参



(以前1000行数据为例)

测试tokenize ()

```
| May | May
```

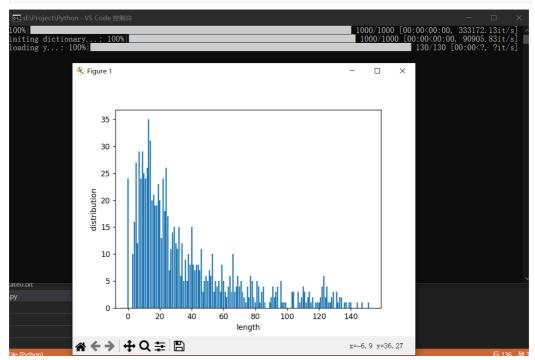
(以第1行数据为例)

测试encode()

测试trim()

测试decode()

测试output_distribution()



从柱状图形状来看,长度的分布类似服从泊松分布 应该取60左右的长度作为标准长度,因为大部分句子的长度<40